# Références croisées
# Spécification et Conception

## 1 Spécification complète

### 1.1 Définitions

- **mot** : Suite de caractères se terminant par un délimiteur.
- **ligne** : Suite de mots terminée par un retour chariot
- **Identificateur** : Mot sensible à la casse composé uniquement de caractères alphanumériques et du caractère '_'. Les commentaires ou chaines litérales ne peuvent contenir d'identifcateurs
- **Délimiteur** : Un caractère représentant une séparation entre deux mots (Ex : une virgule, un espace, un point, ...)
- **Référence croisée** : Fait de rechercher un identificateur dans un ou plusieurs fichiers sources pour déterminer sa localisation

### 1.2 Description du programme

Le but du programme est de permettre de retrouver rapidement l'emplacement d'identifcateurs dans une collection de fichiers. On cherche à connaitre dans quel(s) fichier(s) et à quelle(s) ligne(s) les identifcateurs apparaissent.

Dans le cas où un identifacteur apparaitrait plusieurs fois sur une même ligne, nous avons pris la décision d'afficher la ligne concernée autant de fois qu'il y a d'occurences. En effet, un identificateur est un mot clé significatif pour l'utilisateur. Nous pouvons donc nous attendre à ce qu'il n'apparaisse que peu sur la même ligne.

Ex : Pour le code ci-dessous présent dans le fichier "test.cpp" et avec comme identifacteur la lettre i

```
for( int i = 0; i < 42; i++ );
```

Le programme produira la sortie suivante :
i→test.cpp•1•1•1↓

Par defaut les identificateurs sont les mots clefs utilisés par le langage C++. Il est cependant possible de spécifier un fichier en argument du programme pour définir précisement quelles seront les identifcateurs recherchés par la référence croisée. Le fichier d'identifacteurs ne devra contenir qu'un seul identifacteur valide par ligne, le premier mot de la ligne sera choisi comme tel. Le programme présuposera que le fichier fourni en argument respecte ce formalisme.

Le programme disposera également de la fonctionnalité permettant d'exclure une liste d'identifacteurs.

### 1.3 Spécifications des options

$$tp\_stl\ [-e]\ [-kfichier\_mot\_clef]\ [nomfichier]+$$

**-e** : Permet d'inverser le comportement par défaut du programme. Exclut de la référence croisée tous les mots clefs du C++
**-k fichier_mot_clef** : Permet de spécifier au programme une liste d'identifacateurs à rechercher par la référence croisée
**nomfichier** : Chemin vers un ou plusieurs fichiers où rechercher les identifacateurs

## 2 Tests fonctionnels

### 2.1 Méthodologie

Nous sommes parti du principe que le programme doit produire la même sortie écran (et donc par extension les mêmes données stockées en interne) si il est lancé deux fois sur la même collection de fichiers et avec les mêmes arguments.

En partant de ce principe nous avons réaliser les tests de la façon suivante :

1. Lancer le programme sur une collection de fichier
2. Verifier que la sortie est correcte et respecte les spécifications
3. Relancer le programme dans le même contexte qu'en 1, trier la sortie et rediriger le flux de sortie dans un fichier témoin

Pour automatiser les tests nous avons écrit un script bash qui suit les étapes suivantes pour chaque test :

1. Lancer le programme dans le même contexte que lors de la réalisation du fichier témoin, trier la sortie et rediriger la sortie vers un fichier résultat
2. Faire le hash md5 du fichier résultat et du fichier témoin
3. Comparer les deux hash md5
4. Si les hashs diffèrent c'est que le programme ne possède pas les mêmes données en interne et donc le test échoue
5. Si les hashs sont égaux c'est que le programme possède les mêmes données et donc le test réussi

### 2.2 Critique de la méthode

**Avantages :** Avec cette méthode de réalisation des tests on s'abstrait de la représentation interne des données. On vérifie uniquement que le programme délivre correctement à l'utilisateur les informations voulues. Ainsi tout changement dans la structure de données interne n'affectera pas les tests tant que le programme délivre les memes informations à l'utilisateur.

De plus la réalisation d'un test supplémentaire se fait facilement et ne prend pas beaucoup de temps par rapport à une analyse compléte de la structure de données interne.

Nous gardons une sauvegarde du flux de sortie lors d'un état fonctionnel de l'application, de ce fait, le développeur peut comparer visuellement les deux sorties pour trouver plus facilement les éléments divergeants. D'où un gain de temps lors du débuggage

**Inconvénients :** Avec cette méthode, le formatage des informations à l'utilisateur devient un élément critique. Tout changement dans l'affichage des résultats causera inevitablement l'échec de tous les tests. Toutefois, il peut être facile de créer un script bash permettant de regénérer les fichiers témoins si le développeur est sur des changements qu'il a effectués.

Si un fichier témoin venait à être corrompu cela entrainerait l'échec du test le mettant en jeu.

### 2.3 Test n° 1

**Descriptif :** Le test n° 1 réalise le premier exemple donné par le sujet.
Les fichiers analysés sont :

file1.cpp

```cpp
// affiche le message "Hello world"
int main() {
    cout <<"Hello world"<<endl;
    cout<<endl;
    return 0;
}
```

file1.h

```cpp
int main();
```

key1.txt

```
int
world
template
```

**Résultat attendu :** Nous lançons le programme avec le contexte suivant :

$$tp\_stl \ -e \ -k \ key1.txt \ file1.cpp \ file1.h$$

Nous devons obtenir le résultat ci-dessous après avoir trié la sortie :

file1.res

```
cout        file1.cpp 3 4
endl        file1.cpp 3 4
main        file1.cpp 2       file1.h 1
return        file1.cpp 5
```

## 2.4 Test n° 2

**Descriptif :** Le test n° 2 réalise le deuxième exemple donné par le sujet. Les fichiers analysés sont :

file2.cpp

```cpp
// affiche le message "Hello world"
int main() {
    cout <<"Hello world"<<endl;
    cout<<endl;
    return 0;
}
```

file2.h

```cpp
int main();
```

key2.txt

```
int
world
template
```

**Résultat attendu :** Nous lançons le programme avec le contexte suivant après avoir trié la sortie :

$$tp\_stl \ -k \ key2.txt \ file2.cpp \ file2.h$$

Nous devons obtenir le résultat ci-dessous :

file2.res

```
int         file2.cpp 2         file2.h 1
```

## 2.5 Test n° 3

**Descriptif :** Le test n° 3 réalise le test sur le fichier main de notre programme.
Les fichiers analysés sont :

```
//============================================================================
// Name        : Ref_croisee.cpp
// Author      :
// Version     :
// Copyright   : Your copyright notice
// Description : Hello World in C++, Ansi-style
//============================================================================

#include <iostream>
#include <vector>

#include "CmdLine/cmdLine.hpp"
#include "References/Referenceur.hpp"
#include "References/References.hpp"

using namespace std;
using namespace Reference_croisee;

int main( int argc, char** argv )
{/*{{{*/

CmdLine::Arguments args;
CmdLine::Parser parser( "Permet de referencer des mots clefs a travers des fichiers" );
parser.addOption( "exclude,e",  "Inverse le fonctionnement du programme" );
parser.addOption( "keyword,k",  "Specifie la liste des mots clefs a utiliser", true );

try {
    parser.parse( argc, argv, args );

} catch( exception& e ) {
    cout << "Une erreur c'est produit durant la recuperation de la ligne de commande : "
         << endl << e.what() << endl;
}

//------------------------------------------------------------------------
//  On charge les fichiers a referencer
//------------------------------------------------------------------------
vector<string> ficsReferencer;

if( args.count( "__args__" ) ) {
    ficsReferencer = args.get<vector<string> >( "__args__" );

```

```
43  } else {
44      cerr << "Aucun fichier a referencer !" << endl;
45      return 1;
46  }
47
48  //-------------------------------------------------------------------------
49  //  On charge les mots clefs si ils sont fournis
50  //-------------------------------------------------------------------------
51  string fichierMotClef;
52
53  if( args.count( "keyword" ) ) {
54      fichierMotClef = args.get<string>( "keyword" );
55  }
56
57  //-------------------------------------------------------------------------
58  //  L'etat dans lequel mettre le programme
59  //-------------------------------------------------------------------------
60  bool mode( args.count( "exclude" ) );
61
62
63  References refs;
64
65  //-------------------------------------------------------------------------
66  //  On effectue la reference croisee
67  //-------------------------------------------------------------------------
68  try {
69      Referenceur referenceur( fichierMotClef, mode );
70      referenceur.referencer( ficsReferencer, refs );
71
72  } catch( exception& e ) {
73      cerr << "Une erreur est survenue durant la reference croisee : " << endl;
74      cerr << e.what() << endl;
75  }
76
77
78  //-------------------------------------------------------------------------
79  //  On affiche les resultats
80  //-------------------------------------------------------------------------
81  refs.display( cout );
82
83  return 0;
84     }/*}}}*/
```

**Résultat attendu :** Nous lançons le programme avec le contexte suivant :

$$tp\_stl\ \ file3.cpp$$

Nous devons obtenir le résultat ci-dessous après avoir trié la sortie :

file3.res

```
bool         file3.cpp 60
catch         file3.cpp 30 72
char         file3.cpp 19
cout         file3.cpp 31 81
else         file3.cpp 43
if         file3.cpp 40 53
int         file3.cpp 19 19
namespace         file3.cpp 16 17
return         file3.cpp 45 83
true         file3.cpp 25
try         file3.cpp 27 68
using         file3.cpp 16 17
```

## 2.6 Test n° 4

**Descriptif :** Le fichier à analyser est le même que dans le test précédent, seul le contexte d'execution change.

**Résultat attendu :** Nous lançons le programme avec le contexte suivant :

$$tp\_stl\ file4.cpp$$

Nous devons obtenir le résultat ci-dessous après avoir trié la sortie :

file4.res

```
addOption        file4.cpp 24 25
argc        file4.cpp 19 28
args        file4.cpp 22 28 40 41 53 54 60
Arguments        file4.cpp 22
argv        file4.cpp 19 28
cerr        file4.cpp 44 73 74
CmdLine        file4.cpp 22 23
count        file4.cpp 40 53 60
display        file4.cpp 81
e        file4.cpp 30 32 72 74
endl        file4.cpp 31 32 44 73 74
exception        file4.cpp 30 72
fichierMotClef        file4.cpp 51 54 69
ficsReferencer        file4.cpp 38 41 70
get        file4.cpp 41 54
main        file4.cpp 19
mode        file4.cpp 60 69
parse        file4.cpp 28
Parser        file4.cpp 23
parser        file4.cpp 23 24 25 28
Reference_croisee        file4.cpp 17
referencer        file4.cpp 70
References        file4.cpp 63
Referenceur        file4.cpp 69
referenceur        file4.cpp 69 70
refs        file4.cpp 63 70 81
std        file4.cpp 16
string        file4.cpp 38 41 51 54
vector        file4.cpp 38 41
what        file4.cpp 32 74
```

# 3 Architecture générale

## 3.1 Diagramme de classe du module CmdLine

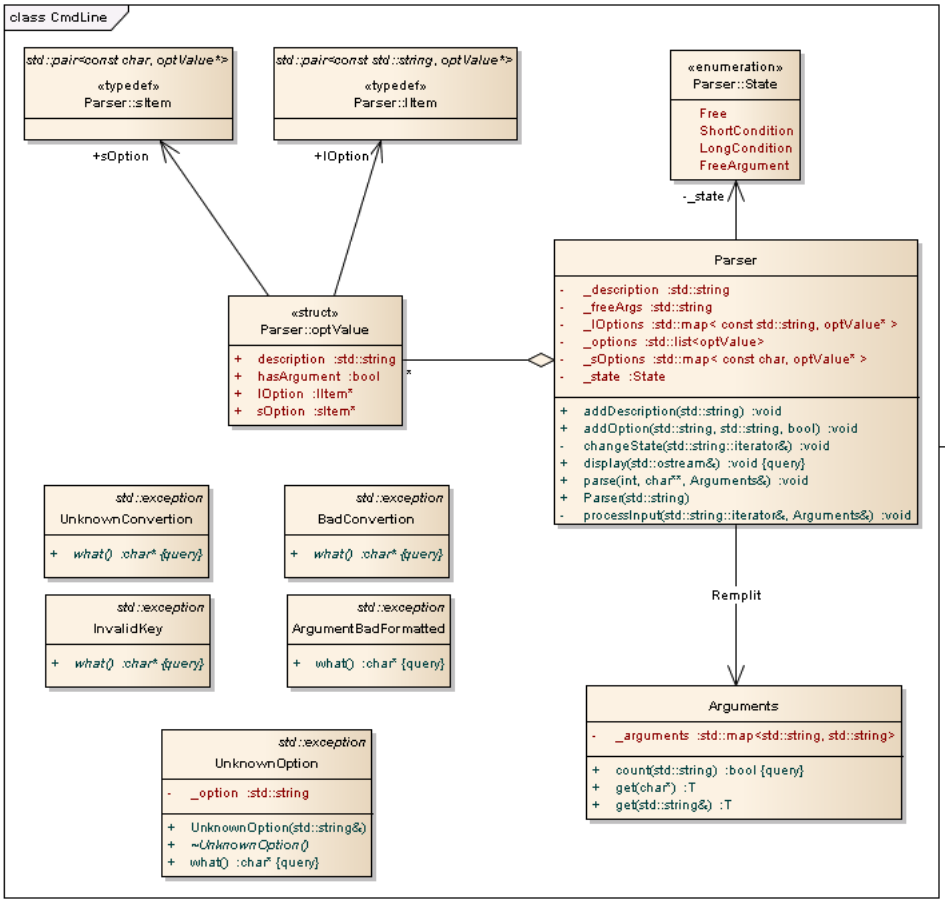


Ce diagramme présente les différentes classes présentes pour extraire les informations de la ligne de commande de façon générique.

La classe “Parser” s’occupe d’extraire les informations de la ligne de commande en vérifiant que les options entrées par l’utilisateur respectent celles définies par le développeur du programme. Au fur et à mesure de l’extraction des données, la classe “Parser” remplit un objet de la classe “Arguments”. La classe “Arguments” sert de conteneur et permet de convertir les options vers des types déterminés à la compilation. Ne sachant pas comment représenter des méthodes génériques en UML, j’ai défini le type de retour des fonctions membres “get” comme étant T. Le module possède ses propres exceptions pour remonter les cas d’erreurs possibles.

## 3.2 Diagramme de classe du module Reference_croisée

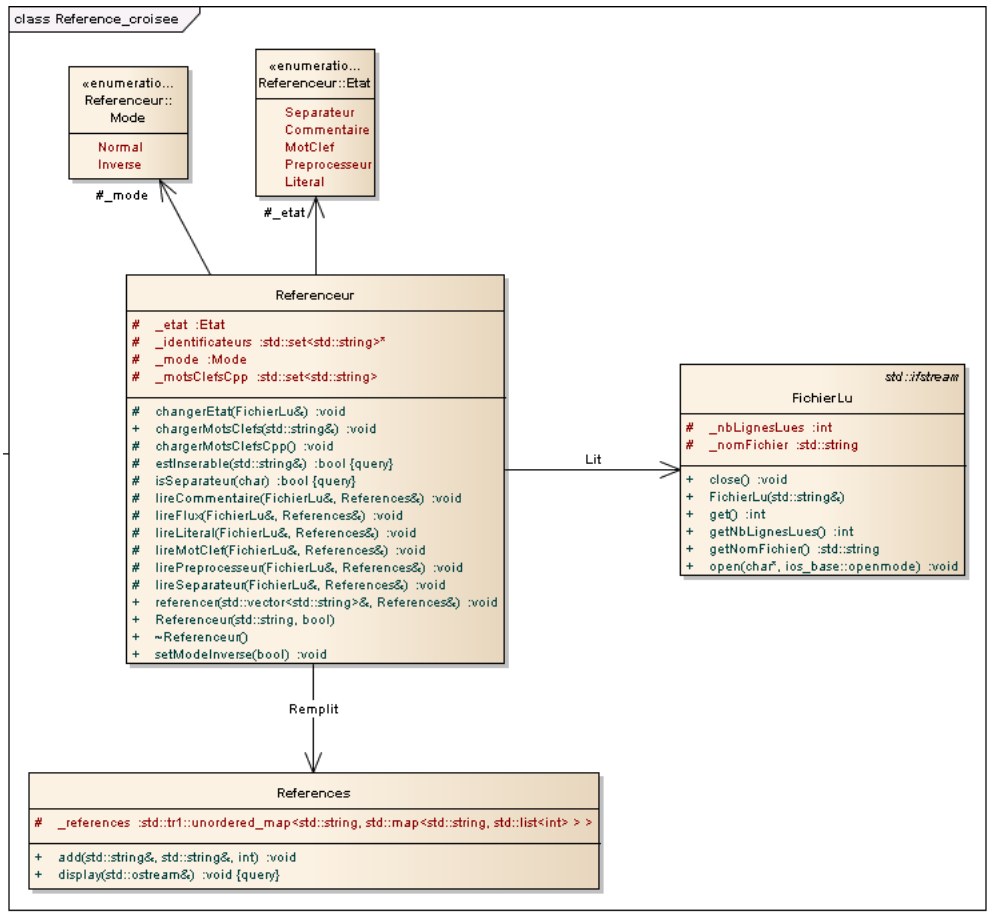


Ce diagramme présente les différentes classes utilisées pour extraire les identifacateurs d'un fichier source C++. Un objet de la classe "FichierLu" permet de lire un fichier stocké sur le disque, tout en fournissant le nombre de lignes déjà lues ainsi que le nom du fichier ouvert.

Un "Referenceur" se sert d'un "FichierLu" pour lire les fichiers sources et en extraire les identifacateurs. Une collection de "References" permet de stocker les identifacteurs qui sont des mots clefs.

### 3.3 Diagramme de classe du module principal

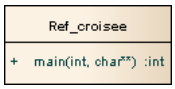


Le module principal permet d'orchestrer les deux modules précédents pour que le programme ait le comportement attendu.

## 4 Algorithmes principaux

### 4.1 Parseur pour la ligne de commandes

Pour extraire les informations de la ligne de commande nous utilisons un automate avec un nombre d'états fini.

**Description des états :**

- **Free** : Lorsque l'automate rencontre quelque chose qui n'est pas un argument ou une option
  Exemple : un caractère séparateur comme un espace
- **ShortCondition** : Lorsque l'automate rencontre une option courte
  Exemple : -e ou -k
- **LongCondition** : Lorsque l'automate rencontre une option longue
  Exemple : –exclude ou –keyword
- **FreeArgument** : Lorsque l'automate rencontre un argument rataché à aucune option
  Exemple : le nom d'un fichier à analyser

Une action est déclenché en fonction de l'état de l'automate. L'action extrait, analyse et stocke l'argument de la ligne de commande s'il est valide, sinon une exception est levé.

### 4.2 Parseur pour les fichiers C++

Pour extraire les informations de la ligne de commande nous utilisons ici aussi un automate avec un nombre fini d'états.

**Description des états :**

- **Separateur** : Lorsque que l'automate rencontre un caractère séparant deux identifacteur
  Exemple : Tout caractère non alphanumériques, le tiret du bas non inclus
- **Commentaire** : Lorsque l'automate rencontre un commentaire sur une seule ligne ou multiligne
  Exemple : /* Ceci est un commentaire */

- **MotClef** : Lorsque l'automate rencontre un identifacteur qui peut être un mot clef potentiel
  Exemple : cout
- **Preprocesseur** : Lorsque l'automate rencontre une instruction preprocesseur
  Exemple : #include <iostream>
- **Literal** : Lorsque l'automate rencontre une chaine de caractères ou un caractère
  Exemple : "Bonjour"

Chaque état déclenche une action propre qui a pour tâche d'avancer dans le fichier tout en extrayant les identifacteurs qui sont des mots clefs.

# 5 Analyse critique des structures de données

## 5.1 Structure des identificateurs

**Analyse des besoins :** Les identificateurs sont extraits d'un ou plusieurs fichiers passés en paramètres. À chaque mot clef rencontré durant l'analyse, il faut vérifier s'il a déjà été référencé auparavant et si non créer son entrée dans la structure de données. Le programme devant tester de nombreuses fois la présence d'un mot clef, nous souhaitons optimiser les accès. De plus chaque mot clef référencé possède une liste de fichiers où il apparait. Il faudra donc pouvoir associer des valeurs aux mots clefs.

**Étude d'un arbre binaire :** Nous cherchons à optimiser les accès dans la structure de données pour les identificateurs. Dans le pire des cas, si l'arbre n'est pas isométrique il faut parcourir tous les noeuds pour savoir si la clef est présente (O(n)). En revanche, dans le cas d'un un arbre équilibré (Ex : un arbre rouge et noir) la recherche est de complexité O(log(n)). Un autre avantage d'un arbre binaire est que les mots clefs seront triés.

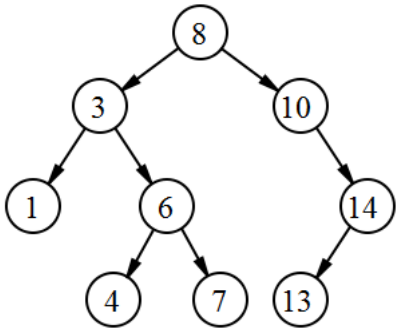


FIGURE 1 – Arbre binaire

**Étude d'une table de hashage :** Dans le cas d'une table de hash l'accès aux données est divisé par une constante C qui est le temps de calcul de la fonction de hash. Nous pouvons dire que l'accès est de complexité O(1) dans le pire des cas. En contrepartie de cette vitesse d'accès, la table de hash prend plus de place en mémoire que les autres structures de données et les clefs ne sont pas triés. De plus il faut que la fonction de hashage soit bien choisi pour qu'il y ait peu de collisions.

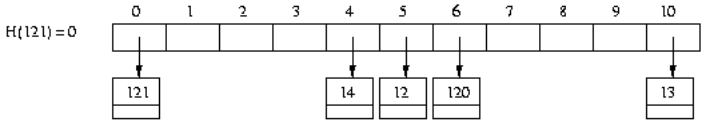


FIGURE 2 – Table de hashage

## 5.2 Structure des références d'occurences

**Analyse des besoins :** A chaque occurence est associé une paire contenant le nom du fichier et le numéro de ligne où elle apprait, il nous faut donc une structure de données pouvant représenter cette multiplicité. Si un mot clef apprait plusieurs fois sur une même ligne nous choisissons de référencer cette ligne autant de fois que le mot clef est présent. La complexité en lecture n'a que peu d'importance dans notre programme car nous devons faire un parcours complet pour afficher toutes les occurences.

Dans un soucis de réutilisabilité, on considère que l'utilisateur pourra en plus de voir apparaître les occurences sur la console, vouloir récupérer une structure de donnée représentant ces occurences.

**Étude d'un arbre de liste :** Nous pouvons utiliser un arbre de liste pour stocker les références des occurences de mot clef. Chaque noeud de l'arbre contiendrait en clef le nom d'un fichier source et en valeur la liste des lignes dans lequel le mot clef est présent. L'avantage de cette méthode est que nous stockons juste ce qu'il faut, il n'y a pas de redondances d'informations. En revanche chaque insertion de référence demandera une complexité moyenne en O(log(n)).

**Étude d'une liste de pair :** Chaque référence d'une occurence étant une paire d'un nom de fichier et d'un numéro de ligne, nous pourrions utiliser une liste pour stocker chacunes de ces pairs. L'avantage de cette méthode est qu'étant donné que nous lisons les fichiers séquentiellements, l'insertion des pairs se faira de manière ordonnée et donc sera de complexité O(1). Le désavantage c'est que nous stockons des doublons, le nom des fichiers où apparaissent les mots clefs.

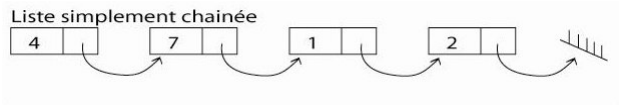


FIGURE 3 – Liste chainée

**Décision :** Dans un but de réutilisabilité nous préférons utliser un arbre de liste pour stocker les références des occurences. Nous evitons la redondance d'informations et ainsi il est sera plus facile de maintenir la cohérence des données si nous souhaitons appliquer des traitements dessus.